

**Aufgabe DT.01:**

Nr.	Alter	Einkommen	Bildung	Kandidat
1	$\geq 35$	hoch	Abitur	O
2	$< 35$	niedrig	Master	O
3	$\geq 35$	hoch	Bachelor	M
4	$\geq 35$	niedrig	Abitur	M
5	$\geq 35$	hoch	Master	O
6	$< 35$	hoch	Bachelor	O
7	$< 35$	niedrig	Abitur	M

**Cal3:**

$$S1 = 4, S2 = 0.7$$

Alter ( $\geq 35, < 35$ ), Einkommen (niedrig, hoch), Bildung (Abitur, Bachelor, Master)

Start: \*

1. /O1/
2. /O2/
3. /O2M1/
4. /O2M2/

$$P(O) = 2/4 = 0.5, P(M) = 2/4 = 0.5, P(O) < 0.7, P(M) < 0.7$$

- Alter(/M1/, \*)
- 5. Alter(/O1M1/, \*)
- 6. Alter(/O1M1/, /O1/)
- 7. Alter(/O1M1/, /O1M1/)
- 1. Alter(/O2M1/, /O1M1/)

$$P(O) = 2/3 = 0.66 < 0.7, P(M) = 1/3 = 0.33 < 0.7 ; P1(O) = 0.5 < 0.7, P1(M) = 0.5 < 0.7$$

- Alter(Einkommen(\*, /O1/), Einkommen(\*, /O1/))
- 2. Alter(Einkommen(/O1/, /O1/), Einkommen(/O1/, /O1/))
- 3. Alter(Einkommen(/O1/, /O1M1/), Einkommen(/O1/, /O1M1/))
- 4. Alter(Einkommen(/O1M1/, /O1M1/), Einkommen(/O1M1/, /O1M1/))
- 5. Alter(Einkommen(/O1M1/, /O2M1/), Einkommen(/O1M1/, /O2M1/))

$$P(O) = 0.5 < 0.7, P(M) = 0.5 < 0.7 ; P1(O) = 2/3 = 0.66 < 0.7, P1(M) = 1/3 = 0.33 < 0.7$$

- Alter(Einkommen(Bildung(\*, \*, /O1/)), Einkommen(Bildung(\*, \*, /O1/)))
- 6. Alter(Einkommen(Bildung(\*, /O1/, /O1/)), Einkommen(Bildung(\*, /O1/, /O1/)))

7. Alter(Einkommen(Bildung(/M1/, /O1/, /O1/)), Einkommen(Bildung(/M1/, /O1/, /O1/)))
1. Alter(Einkommen(Bildung(/O1M1/, /O1/, /O1/)), Einkommen(Bildung(/O1M1/, /O1/, /O1/)))
2. Alter(Einkommen(Bildung(/O1M1/, /O1/, /O2/)), Einkommen(Bildung(/O1M1/, /O1/, /O2/)))

$$P_0(O) = 0.5 < 0.7, P_0(M) = 0.5 < 0.7 ; P_1(O) = 1 \geq 0.7, P_1(M) = 0 < 0.7 ; P_2(O) = 2 \geq 0.7, P_2(M) = 0 < 0.7$$

Keine Differenzierung mehr möglich für Bildung(Arbitur) und gleiche Anzahl an ,O‘ und ,M‘, also zufälliges Auswählen: Bildung(Arbitur) = O

End: Alter(Einkommen(Bildung(O, O, O), Bildung(O, O, O)), Einkommen(Bildung(O, O, O), Bildung(O, O, O)))

### ID3:

- v1 = O, v2 = M
- |v1| = 4, |v2| = 3
- p1 = 4/7 = 0.57, p2 = 3/7 = 0.43

$$H(V) = -(0.57 \cdot \log_2(0.57) + 0.43 \cdot \log_2(0.43)) = 0.986$$

- Alter =  $\geq 35$  liefert  $S_0 = \{1, 3, 4, 5\}$
- Alter =  $< 35$  liefert  $S_1 = \{2, 6, 7\}$
- $P(\geq 35) = 4/7 = 0.57, P(< 35) = 3/7 = 0.43$

$$\begin{aligned} R(S, \text{Alter}) &= 0.57 \cdot H(\{1, 3, 4, 5\}) + 0.43 \cdot H(\{2, 6, 7\}) \\ &= 0.57 \cdot (-1/2 \cdot \log_2(1/2) - 1/2 \cdot \log_2(1/2)) + \\ &\quad 0.43 \cdot (-2/3 \cdot \log_2(2/3) - 1/3 \cdot \log_2(1/3)) \\ &= 0.57 + 0.395 = 0.965 \text{ Bit} \end{aligned}$$

- Einkommen = niedrig liefert  $S_0 = \{2, 4, 7\}$
- Einkommen = hoch liefert  $S_1 = \{1, 3, 5, 6\}$
- $P(\text{niedrig}) = 3/7, P(\text{hoch}) = 4/7$

$$\begin{aligned} R(S, \text{Einkommen}) &= 3/7 \cdot H(\{2, 4, 7\}) + 4/7 \cdot H(\{1, 3, 5, 6\}) \\ &= 3/7 \cdot (-1/3 \cdot \log_2(1/3) - 2/3 \cdot \log_2(2/3)) \\ &\quad 4/7 \cdot (-3/4 \cdot \log_2(3/4) - 1/4 \cdot \log_2(1/4)) \\ &= 0.394 + 0.464 = 0.858 \end{aligned}$$

- Bildung = Arbitur liefert  $S_0 = \{1, 4, 7\}$
- Bildung = Bachelor liefert  $S_1 = \{3, 6\}$
- Bildung = Master liefert  $S_2 = \{2, 5\}$
- $P(\text{Arbitur}) = 3/7, P(\text{Bachelor}) = 2/7, P(\text{Master}) = 2/7$

$$\begin{aligned}
 R(S, \text{Bildung}) &= 3/7 * H(\{1, 4, 7\}) + 2/7 * H(\{3, 6\}) + 2/7 * H(\{2, 5\}) \\
 &= 3/7 * (-1/3 * \log_2(1/3) - 2/3 * \log_2(2/3)) + \\
 &\quad 2/7 * (-1/2 * \log_2(1/2) - 1/2 * \log_2(1/2)) + \\
 &\quad 2/7 * (-2/2 * \log_2(2/2) - 0/2 * \log_2(0/2)) \\
 &= 0.394 + 0.286 + 0 = 0.68
 \end{aligned}$$

$$\text{Gain}(S, \text{Alter}) = H(V) - R(S, \text{Alter}) = 0.986 - 0.956 = 0.03 \text{Bit}$$

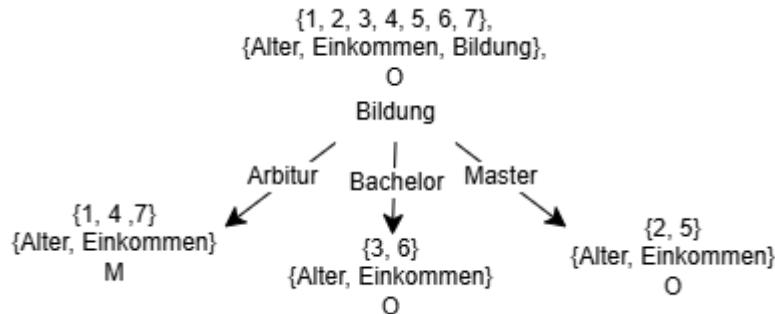
$$\text{Gain}(S, \text{Einkommen}) = 0.986 - 0.858 = 0.128 \text{Bit}$$

$$\text{Gain}(S, \text{Bildung}) = 0.986 - 0.68 = 0.306 \text{Bit}$$

$\{1, 2, 3, 4, 5, 6, 7\}, \{\text{Alter, Einkommen, Bildung}\}, O$

Bildung hat den höchsten Gain-Wert:

Teil-Baum:



$\{1, 4, 7\}, \{\text{Alter, Einkommen}\}, M$

$$H(V(\text{Arbitur})) = -(1/3 * \log_2(1/3) + 2/3 * \log_2(2/3)) = 0.918$$

- Arbitur( $\text{Alter} \geq 35$ ) liefert  $S_0 = \{1, 4\}$
- Arbitur( $\text{Alter} < 35$ ) liefert  $S_1 = \{7\}$
- $P(\geq 35) = 2/3, P(< 35) = 1/3$

$$R(S, \text{Arbitur}(\text{Alter})) = 2/3 * H(\{1, 4\}) + 1/3 * H(\{7\})$$

$$= 2/3 * (1) + 1/3 * 0$$

$$= 2/3 = 0.66$$

- Arbitur(Einkommen) = niedrig liefert  $S_0 = \{4, 7\}$
- Arbitur(Einkommen) = hoch liefert  $S_1 = \{1\}$
- $P(\text{niedrig}) = 2/3, P(\text{hoch}) = 1/3$

$$R(S, \text{Arbitur(Einkommen)}) = 2/3 * H(\{4, 7\}) + 1/3 * H(\{1\})$$

$$= 2/3 * (0) + 1/3 * (0)$$

$$= 0$$

$$\text{Gain}(S, \text{Arbitur(Alter)}) = 0.918 - 0.66 = 0.258$$

$$\text{Gain}(S, \text{Arbitur(Einkommen)}) = 0.918 - 0 = 0.918$$

Arbitur(Einkommen) hat den höchsten Gain-Wert.

$\{3, 6\}, \{\text{Alter, Einkommen}\} O$

$$H(V(\text{Bachelor})) = -(1/2 * \log_2(1/2) + 1/2 * \log_2(1/2)) = 1$$

- Bachelor(Alter) =  $\geq 35$  liefert  $S_0 = \{3\}$
- Bachelor(Alter) =  $< 35$  liefert  $S_1 = \{6\}$
- $P(\geq 35) = 1/2, P(< 35) = 1/2$

$$R(S, \text{Bachelor(Alter)}) = 1/2 * H(\{3\}) + 1/2 * H(\{6\}) = 0$$

- Bachelor(Einkommen) = niedrig liefert  $S_0 = \{\}$
- Bachelor(Einkommen) = hoch liefert  $S_1 = \{3, 6\}$
- $P(\text{niedrig}) = 0, P(\text{hoch}) = 1$

$$R(S, \text{Bachelor(Einkommen)}) = 0 * H(\{\}) + 1 * H(\{3, 6\})$$

$$= 0 + 1 * (1) = 1$$

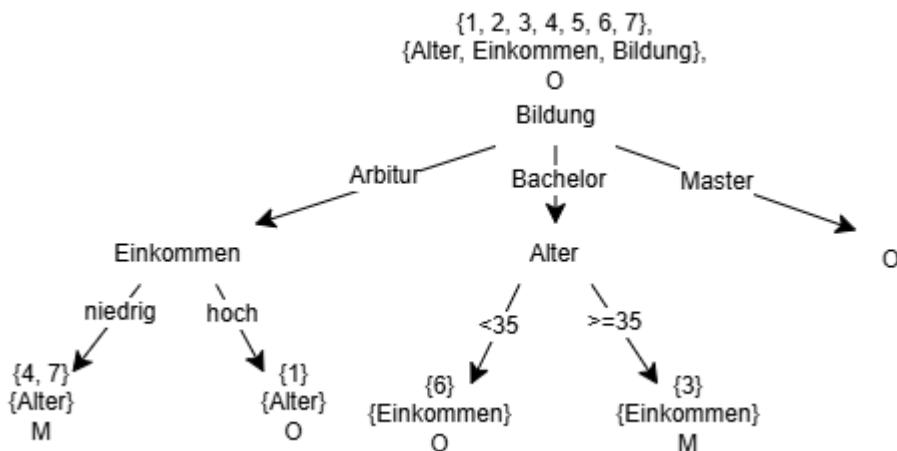
$$\text{Gain}(S, \text{Bachelor(Alter)}) = 1 - 0 = 1$$

$$\text{Gain}(S, \text{Bachelor(Einkommen)}) = 1 - 1 = 0$$

Bachelor(Alter) hat einen höheren Gain-Wert.

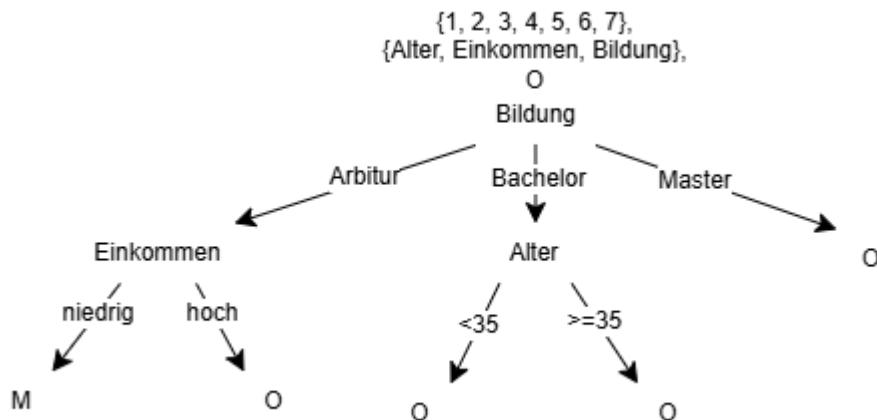
Master Pfad hat zweimal die selben Kandidaten also wird der Knoten zu ,O‘.

Teil-Baum:



- Pfad **Arbitur(niedrig)** hat zwei gleiche Kandidaten somit wird der Knoten zu ,M'
- Pfad **Bachelor(<35)** hat nur noch einen Vektor also wird der Knoten zu ,O'
- Pfad **Bachelor( $\geq 35$ )** hat nur noch einen Vektor also wird der Knoten zu ,M'

Ganzer-Baum:



**DTL.02:**

$$x_3(x_2(x_1(C, A), x_1(B, A)), x_1(x_2(C, B), A))$$

1. Schritt: Transformationsregel:

$$x_2(x_1(C, A), x_1(B, A)) \Leftrightarrow x_1(x_2(C, B), x_2(A, A))$$

$$\text{Baum: } x_3(x_1(x_2(C, B), x_2(A, A)), x_1(x_2(C, B), A))$$

2. Schritt: bedingt irrelevante Attribute:

$$x_1(x_2(C, B), x_2(A, A)) \rightarrow x_1(x_2(C, B), A)$$

$$\text{Baum: } x_3(x_1(x_2(C, B), A), x_1(x_2(C, B), A))$$

3. Schritt: bedingt irrelevante Attribute:

$$x_3(x_1(x_2(C, B), A), x_1(x_2(C, B), A)) \rightarrow x_3(x_2(C, B), A)$$

$$\text{fertiger Baum: } x_3(x_2(C, B), A))$$

### Aufgabe DT.03:

#### 1.

Zoo:

```
J48 pruned tree
-----
feathers <= 0
|   milk <= 0
|   |   backbone <= 0
|   |   |   airborne <= 0
|   |   |   |   predator <= 0
|   |   |   |   |   legs <= 2: shellfish (2.0)
|   |   |   |   |   |   legs > 2: insect (2.0)
|   |   |   |   |   |   predator > 0: shellfish (8.0)
|   |   |   |   |   |   |   airborne > 0: insect (6.0)
|   |   |   |   |   |   |   |   backbone > 0
|   |   |   |   |   |   |   |   |   fins <= 0
|   |   |   |   |   |   |   |   |   |   tail <= 0: amphibian (3.0)
|   |   |   |   |   |   |   |   |   |   |   tail > 0: reptile (6.0/1.0)
|   |   |   |   |   |   |   |   |   |   |   fins > 0: fish (13.0)
|   |   |   |   |   |   |   |   |   |   |   milk > 0: mammal (41.0)
feathers > 0: bird (20.0)
```

==== Confusion Matrix ===

a	b	c	d	e	f	g	<-- classified as
41	0	0	0	0	0	0	a = mammal
0	13	0	0	0	0	0	b = fish
0	0	20	0	0	0	0	c = bird
0	0	0	10	0	0	0	d = shellfish
0	0	0	0	8	0	0	e = insect
0	0	0	0	0	3	1	f = amphibian
0	0	0	0	0	0	5	g = reptile

Erklärung: 20 Tiere wurden richtig als Vögel klassifiziert, 41 als Säugetiere, 13 als Fische, 6 als Reptile, 3 als Amphibien, 8 als Insekten, 10 als Shellfish.

Ein Tier wurde falsch als Reptil klassifiziert.

Die Fehlerrate liegt bei 0.9901%

Durch die Confusion Matrix sieht man das alle Tiere außer einem richtig klassifiziert wurde.

Restaurant:

==== Confusion Matrix ===

a	b	c	d	e	f	g	<-- classified as
4	0	0	0	0	0	0	a = Yes
0	0	1	0	0	0	0	b = No
0	0	2	0	0	0	0	c = Yes
0	0	0	2	0	0	0	d = No
0	0	0	0	1	0	0	e = No
0	0	1	0	0	0	0	f = No
0	0	0	0	1	0	0	g = No

```
J48 pruned tree
-----
patrons = Some: Yes (3.0)
patrons = Full: Yes (4.0/2.0)
patrons = Some: Yes (1.0)
patrons = Full: No (2.0)
patrons = None: No (2.0/1.0)
```

Erklärung: Der Baum zeigt, wann in der Regel ein Kunde warten muss. Dabei ist das wichtigste Attribut ‚patrons‘ was die Anzahl der Gäste ist. Wenn also nur ein paar Gäste im Restaurant dann warten Gäste in drei Trainingsbeispielen oder nur in einem. Wenn es voll ist, warten Gäste bei 6 Beispielen (wobei zwei davon falsch klassifiziert wurden) oder es wartet kein Gast in zwei Beispielen. Und wenn es leer ist, wartet keine in drei Beispielen, wo auch wieder ein Trainingsbeispiel falsch klassifiziert wurde.

Die Fehlerrate liegt bei 25%.

## 2.

Unterschied Nominal, Ordinal, String: Ordinal sind reals und integer, nominal sind Objekte oder Klassen und Strings sind Text-Werte.

Zoo:

```
J48 pruned tree
-----
feathers <= 0
|   milk <= 0
|   |   backbone <= 0
|   |   |   airborne <= 0
|   |   |   |   predator <= 0
|   |   |   |   |   legs <= 2: shellfish (2.0)
|   |   |   |   |   |   legs > 2: insect (2.0)
|   |   |   |   |   |   predator > 0: shellfish (8.0)
|   |   |   |   |   |   airborne > 0: insect (6.0)
|   |   |   |   |   |   backbone > 0
|   |   |   |   |   |   fins <= 0
|   |   |   |   |   |   |   tail <= 0: amphibian (3.0)
|   |   |   |   |   |   |   tail > 0: reptile (6.0/1.0)
|   |   |   |   |   |   |   fins > 0: fish (13.0)
|   |   |   |   |   |   |   milk > 0: mammal (41.0)
|   |   |   |   |   |   |   feathers > 0: bird (20.0)
```

==== Confusion Matrix ===							
a	b	c	d	e	f	g	<- classified as
41	0	0	0	0	0	0	a = mammal
0	13	0	0	0	0	0	b = fish
0	0	20	0	0	0	0	c = bird
0	0	0	10	0	0	0	d = shellfish
0	0	0	0	8	0	0	e = insect
0	0	0	0	0	3	1	f = amphibian
0	0	0	0	0	0	5	g = reptile

Fehlerrate = 0.9901%

Fazit: Gleicher Baum und selbe Fehlerrate wie bei dem ersten Teil.

Restaurant:

Seite 7

```
J48 pruned tree
```

```
-----
patrons = Some: Yes (3.0)
patrons = Full: Yes (4.0/2.0)
patrons = Some: Yes (1.0)
patrons = Full: No (2.0)
patrons = None: No (2.0/1.0)
```

Fehlerrate = 25%

```
==== Confusion Matrix ===
```

a	b	c	d	e	f	g	<-- classified as
4	0	0	0	0	0	0	a = Yes
0	0	1	0	0	0	0	b = No
0	0	2	0	0	0	0	c = Yes
0	0	0	2	0	0	0	d = No
0	0	0	0	1	0	0	e = No
0	0	1	0	0	0	0	f = No
0	0	0	0	1	0	0	g = No

Id3

```
est = 0-10
| patrons = Some: Yes
| patrons = Full: null
| patrons = Some: Yes
| patrons = Full: null
| patrons = None: No
est = 30-60: No
est = 10-30: Yes
est = >60: No
est = 0-10: Yes
est = 0-10
| hun = Yes: Yes
| hun = No: No
| hun = Yes: null
| hun = No: null
est = 10-30: No
est = 30-60: Yes
```

Fehlerrate = 0%

```
==== Confusion Matrix ===
```

a	b	c	d	e	f	g	<-- classified as
4	0	0	0	0	0	0	a = Yes
0	1	0	0	0	0	0	b = No
0	0	2	0	0	0	0	c = Yes
0	0	0	2	0	0	0	d = No
0	0	0	0	1	0	0	e = No
0	0	0	0	0	1	0	f = No
0	0	0	0	0	0	1	g = No